

概述：因果推断模型之合成控制法(SCM)

合成控制法 (Synthetic Control Method, SCM) 的数学本质是一个带约束的凸优化问题。它的目标是通过求解权重，使得合成的控制对象在政策干预前最接近真实的处理对象。

以下是合成控制法推导与求解过程中的所有核心公式：

1. 基础符号定义

- $J + 1$: 总共的实体（地区、个体）数量。
- $i = 1$: 受到政策干预的处理对象 (Treated Unit)。
- $i = 2, 3, \dots, J + 1$: 未受政策干预的控制池实体 (Donor Pool, 共 J 个)。
- T : 总时间期数。
- T_0 : 政策干预发生的时点 ($1 \leq T_0 < T$)。
- 因此:
 - $1 \dots T_0$ 为**政策前时期** (Pre-treatment period)。
 - $T_0 + 1 \dots T$ 为**政策后时期** (Post-treatment period)。
- Y_{it} : 实体 i 在时间 t 的观测结果变量。
- Y_{1t}^N : 处理对象在没有受到政策干预时的**反事实结果** (Counterfactual)。
- Y_{1t}^I : 处理对象在受到政策干预后的**实际观测结果**。

2. 核心因果效应定义

在政策后时期 ($t > T_0$)，我们真正想求的因果效应 (Treatment Effect) α_{1t} 为：

$$\alpha_{1t} = Y_{1t}^I - Y_{1t}^N \quad (\text{对于 } t > T_0)$$

- **痛点**：实际中我们能观察到 Y_{1t}^I ，但**无法观察到** Y_{1t}^N 。合成控制法的核心任务就是构造一个估计值 $\hat{Y}_{1t}^N$ 来替代真实的 Y_{1t}^N 。

3. 潜在结果模型 (Factor Model)

理论上，Abadie 等人 (2010) 基于以下因子模型来保证合成控制的合理性：

$$Y_{it}^N = \delta_t + \theta_t Z_i + \lambda_t \mu_i + \epsilon_{it}$$

- δ_t : 时间固定效应。
- Z_i : 不受政策影响的观察到的协变量（控制变量）向量。
- θ_t : 未知的参数向量。
- λ_t : 不可观测的共同因子的时间变动向量。
- μ_i : 不可观测的个体固定效应。
- ϵ_{it} : 均值为零的短期冲击（误差项）。

4. 权重矩阵与约束条件

合成控制法用控制池中各实体的加权平均来代表反事实：

$$\hat{Y}_{1t}^N = \sum_{j=2}^{J+1} w_j Y_{jt}$$

其中 $W = (w_2, w_3, \dots, w_{J+1})'$ 是权重向量，必须满足两个严格的非负和凸性约束：

1. 非负性约束：

$$w_j \geq 0 \quad (\text{对于 } j = 2, 3, \dots, J + 1)$$

2. 加和为 1 约束 (凸组合)：

$$\sum_{j=2}^{J+1} w_j = 1$$

注：这两个约束防止了外推 (Extrapolation)，即合成对象不会使用控制池中没有的极值，增强了结果的稳健性。

5. 核心优化问题（如何求权重 W 和变量重要性 V ）

权重 W 的确定是通过最小化政策前时期 ($1 \dots T_0$) 处理对象与合成对象之间的特征差距来完成的。这是一个双层优化问题：

第一层：给定特征权重矩阵 V 时，求实体权重 $W(V)$

最小化政策前特征的加权均方距离：

$$\min_W (X_1 - X_0 W)' V (X_1 - X_0 W)$$

- X_1 ：处理对象（实体 1）在政策实施前的特征向量（包含部分历史结果变量和控制变量）。
- X_0 ：控制池中所有其他 J 个实体在相同政策前时期的特征矩阵。
- V ：一个对角矩阵 (Diagonal Matrix)，其对角线元素代表各个控制变量的重要性权重。

$$V = \begin{pmatrix} v_1 & 0 & \dots \\ 0 & v_2 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}。$$

第二层：求最优变量重要性权重 V

选择一个矩阵 V ，使得政策前时期结果变量的均方预测误差 (MSPE) 达到最小：

$$\min_V (Y_1 - Y_0 W^*(V))' (Y_1 - Y_0 W^*(V))$$

- Y_1 ：处理对象在政策实施前各期的实际结果向量。
- Y_0 ：控制池实体在政策实施前各期的实际结果矩阵。
- $W^*(V)$ ：由第一层优化解出的依赖于 V 的最优权重。

6. 最终因果效应估计公式

一旦通过优化求解出了最优权重向量 $\hat{W} = (w_2^*, w_3^*, \dots, w_{J+1}^*)'$ ，在政策发生后 ($t > T_0$)，因果效应的估计值 $\hat{\alpha}_{1t}$ 为：

$$\hat{\alpha}_{1t} = Y_{1t}^I - \sum_{j=2}^{J+1} w_j^* Y_{jt} \quad (\text{对于 } t > T_0 + 1, \dots, T)$$

7. 安慰剂检验 (Placebo Test) 的统计量公式

为了检验估计出的因果效应是否显著 (类似于传统统计学中的 p 值)，通常会计算均方预测误差比 (RMSPE Ratio)：

$$\text{RMSPE} = \frac{\sqrt{\frac{1}{T - T_0} \sum_{t=T_0+1}^T (Y_{1t} - \hat{Y}_{1t})^2}}{\sqrt{\frac{1}{T_0} \sum_{t=1}^{T_0} (Y_{1t} - \hat{Y}_{1t})^2}}$$

- **分子**：政策实施后的均方预测误差 (评估偏离程度)。
- **分母**：政策实施前的均方预测误差 (评估拟合优度)。
- **逻辑**：如果真实处理对象的 RMSPE 比控制池中其他“假装受政策影响的实体” (安慰剂) 大得多，则说明该政策效应极具统计显著性。

证明：因果推断模型之合成控制法(SCM)提到的需要最小化的目标函数和约束条件，一定可以归为带直线约束的二次规划类算法问题

从线性代数和凸优化理论的视角，一步步推导证明合成控制法 (SCM) 的第一层优化问题 (权重 W 的求解) 在数学本质上, 完美等价于一个带直线约束的凸二次规划 (Convex Quadratic Programming, QP) 问题。

一、证明的命题定义

【已知条件】:

在合成控制法中, 若给定特征权重矩阵 V (后面会补充繁琐的矩阵 V 构造细节), 我们需要求解控制池权重向量 W 。

1. 处理对象 (Treated Unit) 的特征向量记为 $X_1 \in \mathbb{R}^{K \times 1}$ 。
2. 控制池 (Donor Pool) 的特征矩阵记为 $X_0 \in \mathbb{R}^{K \times J}$ (J 为控制池实体数, K 为特征数)。
3. 特征重要性矩阵 $V \in \mathbb{R}^{K \times K}$ 为非负对角矩阵 (即 $V = V^T$, 且 $V \geq 0$)。
4. 待优化变量为控制权重向量 $W = (w_1, w_2, \dots, w_J)^T \in \mathbb{R}^{J \times 1}$ 。

【SCM 原优化问题】:

$$\begin{aligned} \min_{w_1, w_2, \dots, w_J} \quad & L(w_1, w_2, \dots, w_J) = \sum_{k=1}^K v_k \left(X_{k1} - \sum_{j=1}^J X_{kj} w_j \right)^2 \\ \min_{W \in \mathbb{R}^J} \quad & L(W) = (X_1 - X_0 W)^T V (X_1 - X_0 W) \\ \text{s.t.} \quad & \sum_{j=1}^J w_j = 1, \quad w_j \geq 0 \quad (\forall j = 1, \dots, J) \end{aligned}$$

X_1 $K \times 1$
 X_0 $K \times J$
 W $J \times 1$
 V $K \times K$

【QP 标准型定义】:

一个标准的二次规划问题定义为:

$$\begin{aligned} \min_x \quad & f(x) = \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad & A x \leq b, \quad E x = d, \quad l \leq x \leq u \end{aligned}$$

【求证目标】:

证明 SCM 原优化问题可以通过严格的代数变换, 完全映射为上述 QP 标准型, 且保证海森矩阵 Q 是半正定的 (即该问题为凸二次规划)。

二、数学推导与证明过程

第一部分：目标函数 (Objective Function) 的映射与降维

我们将 SCM 的目标函数 $L(W)$ 展开, 利用矩阵乘法的分配律和转置法则 $(AB)^T = B^T A^T$:

$$\begin{aligned} L(W) &= (X_1 - X_0 W)^T V (X_1 - X_0 W) \\ &= (X_1^T - W^T X_0^T) V (X_1 - X_0 W) \\ &= X_1^T V X_1 - X_1^T V X_0 W - W^T X_0^T V X_1 + W^T X_0^T V X_0 W \end{aligned}$$

观察中间的两项交叉项:

- $X_1^T V X_0 W$ 的维度是 $(1 \times K) \times (K \times K) \times (K \times J) \times (J \times 1) = (1 \times 1)$ 。
- 既然它是一个标量 (标量的转置等于其自身), 我们有:

$$(X_1^T V X_0 W)^T = W^T X_0^T V^T (X_1^T)^T$$

- 由于 V 是对角矩阵，满足对称性 $V^T = V$ ，所以：

$$(X_1^T V X_0 W)^T = W^T X_0^T V X_1$$

- 因此，中间的两项完全相等，可以合并：

$$-X_1^T V X_0 W - W^T X_0^T V X_1 = -2W^T X_0^T V X_1$$

将合并后的结果代回原式，并按照二次项、一次项、常数项重新排列：

$$L(W) = W^T (X_0^T V X_0) W - 2(X_0^T V X_1)^T W + X_1^T V X_1$$

在最优化理论中，由于 $X_1^T V X_1$ 是不包含变量 W 的纯常数项，它只会让整口“抛物线大碗”在空间中上下平移，**绝对不会改变最低点的水平坐标 W^*** 。因此，在求 $\arg \min$ 时可以直接舍去（或视作常数偏移）。

为了凑成标准 QP 模板中的 $\frac{1}{2}x^T Qx + c^T x$ ，我们提取系数：

令：

$$Q = 2X_0^T V X_0 \quad (Q \in \mathbb{R}^{J \times J})$$

$$c = -2(X_0^T V X_1) \quad (c \in \mathbb{R}^{J \times 1})$$

于是目标函数完美映射为 QP 标准形式：

$$\arg \min_W L(W) \Leftrightarrow \arg \min_W \frac{1}{2} W^T Q W + c^T W$$

第二部分：二次项矩阵 Q 的凸性证明（核心）

要证明它是一个完美的凸二次规划（一定存在全局极小值），必须严谨证明提取出的矩阵 $Q = 2X_0^T V X_0$ 是对称半正定矩阵（ $Q \geq 0$ ）。

1. 证明对称性（Symmetric）：

$$Q^T = (2X_0^T V X_0)^T = 2(X_0)^T V^T (X_0^T)^T = 2X_0^T V X_0 = Q$$

故 Q 为对称矩阵。

2. 证明半正定性（Positive Semi-Definite）：

根据半正定矩阵的严格代数定义：对于任意非零列向量 $z \in \mathbb{R}^{J \times 1}$ ，必有二次型 $z^T Q z \geq 0$ 。

代入 Q 的定义式展开：

$$z^T Q z = z^T (2X_0^T V X_0) z = 2(X_0 z)^T V (X_0 z)$$

令列向量 $y = X_0 z \in \mathbb{R}^{K \times 1}$ ，上式化为：

$$z^T Q z = 2y^T V y$$

由于 V 是对角线元素非负的对角矩阵（即 $V = \text{diag}(v_1, v_2, \dots, v_K)$ 且 $v_k \geq 0$ ），展开该内积形式得到：

$$2y^T V y = 2 \sum_{k=1}^K v_k y_k^2$$

因为对于所有的实数 y_k ，其平方 $y_k^2 \geq 0$ ，且权重 $v_k \geq 0$ ，所以求和项必然大于或等于 0：

$$2 \sum_{k=1}^K v_k y_k^2 \geq 0 \Rightarrow z^T Q z \geq 0$$

结论： Q 是半正定矩阵，该优化问题为严格的凸二次规划。

第三部分：约束条件（Constraints）的线性映射

SCM 存在两个针对 W 的约束条件，我们用矩阵向量的形式将其重写，以对齐 QP 标准型的线性约束。

1. 加和为 1 约束（凸组合约束）：

原式： $\sum_{j=1}^J w_j = 1$

定义全 1 行向量 $\mathbf{1}^T = [1, 1, \dots, 1] \in \mathbb{R}^{1 \times J}$ 。

转化为线性等式约束（对应 QP 标准型的 $Ex = d$ ）：

$$\underbrace{\mathbf{1}^T}_E W = \underbrace{1}_d$$

2. 非负性约束（无穿透约束）：

原式： $w_j \geq 0, \forall j$

定义全 0 列向量 $\mathbf{0} \in \mathbb{R}^{J \times 1}$ 。

转化为边界约束（对应 QP 标准型的 $l \leq x \leq u$ ）：

$$\underbrace{\mathbf{0}}_l \leq W \leq \underbrace{+\infty}_u$$

(注：SCM 没有任何不等式约束 $Ax \leq b$ ，因此在映射时将 A 视作空矩阵即可。)

三、 终局结论 (Q.E.D.)

通过以上代数变换，我们已严谨地证明了，给定 V 的合成控制法求解问题：

$$\min_W (X_1 - X_0 W)^T V (X_1 - X_0 W) \quad \text{s.t.} \quad \sum w_j = 1, W \geq 0$$

完全且唯一地等价于以下的凸二次规划（Convex QP）问题：

$$\begin{aligned} \min_W & \frac{1}{2} W^T Q W + c^T W \\ \text{s.t.} & \quad EW = d, \quad l \leq W \leq u \end{aligned}$$

映射参数表：

- $Q = 2X_0^T V X_0$ （对称半正定）
- $c = -2X_0^T V X_1$
- $E = \mathbf{1}^T$
- $d = 1$
- $l = \mathbf{0}, u = +\infty$

因此，SCM 提到的需要最小化的目标函数和约束条件，一定可以归为带直线约束的二次规划算法问题。证毕。

附录：详解构造特征重要性矩阵 V 的嵌套双层优化法

特征重要性矩阵 V 是一个 $K \times K$ 的非负对角矩阵，对角线上的元素 $v_k \geq 0$ 决定了第 k 个预测特征在合成匹配时的相对权重。在实际应用中，构造 V 矩阵主要有以下四种方式，其中最标准的是**嵌套双层优化算法（Bi-level Optimization）**。

1. 嵌套双层优化法（Data-Driven Bi-level Optimization）

这是合成控制法（SCM）创始人 Abadie 等人提出的最标准、最经典的构造方法。它通过**内外两层循环联合求解**：

- **内层优化（求解 W ）**：固定当前的 V ，通过二次规划（QP）求解出最优的控制组权重向量 $W^*(V)$ ，使得特征差距最小化：

$$W^*(V) = \arg \min_W (X_1 - X_0 W)^T V (X_1 - X_0 W)$$

- **外层优化（求解 V ）**：寻找一个归一化的对角矩阵 V ，使得根据 $W^*(V)$ 合成出的结果变量 Y ，在政策实施前的时期 (T_{pre}) 与真实处理组的**均方预测误差（MSPE）**最小：

$$\min_{V \geq 0, \text{Tr}(V)=1} \frac{1}{|T_{pre}|} \sum_{t \in T_{pre}} \left(Y_{1t} - \sum_{j=1}^J w_j^*(V) Y_{jt} \right)^2$$

合成控制组不仅“特征像”，而且“历史结果变量的轨迹也最像”。

从凸优化和非凸优化角度深入解释嵌套双层优化法。

合成控制法（SCM）的嵌套双层优化，是一种典型的“主从博弈（Leader-Follower Problem）”数学结构。外层优化（领导者）寻找最优的特征权重矩阵 V ，内层优化（执行者）在给定 V 的前提下计算最佳的控制组权重 W 。

A 双层优化的整体架构

层次	求解变量	优化算法	物理与数学意义
内层优化（执行层）	$W = (w_1, \dots, w_J)^T$	凸二次规划（QP / SLSQP）	找最近特征 ：在给定特征权重 V 下，寻找使得控制组与处理组特征差距最小的权重 $W^*(V)$ 。
外层优化（决策层）	V $= \text{diag}(v_1, \dots, v_K)$	L-BFGS-B / 拟牛顿法 / 导数无关优化	找最准拟合 ：寻找一组特征重要性 V ，使得根据内层算出的 $W^*(V)$ 合成出的历史结果变量轨迹（ Y ）误差最小。

B 外层（第二层）优化详解：寻找最优 V

外层优化是整个算法的“大脑”，它的工作是评价内层算出的权重 W 到底好不好，并据此调整 V 。

1. 数学目标函数与约束

外层的目标是最小化政策实施前时期（ T_{pre} ）内，真实处理组 Y_1 与合成控制组在结果变量上的均方预测误差（MSPE）：

$$\begin{aligned} \min_V \quad \text{MSPE}(V) &= \frac{1}{|T_{pre}|} \sum_{t \in T_{pre}} \left(Y_{1t} - \sum_{j=1}^J w_j^*(V) Y_{jt} \right)^2 \\ \text{s.t.} \quad v_k &\geq 0 \quad (\forall k = 1, \dots, K), \quad \sum_{k=1}^K v_k = 1 \end{aligned}$$

2. 核心难点：隐函数依赖（Implicit Function）与“黑盒”映射

外层优化最大的求解痛点在于：目标函数中没有直接出现 V ！

V 是通过控制内层 QP 问题的“大碗形状”，间接影响内层输出的 $W^*(V)$ ，再由 $W^*(V)$ 影响最终的 MSPE：

$$V \xrightarrow{\text{改变 QP 目标函数形状}} W^*(V) \xrightarrow{\text{加权合成历史轨迹 } Y} \text{MSPE}(V)$$

在数学上， $W^*(V)$ 并不是一个显式的代数表达式，而是一个以完整算法求解过程为载体的隐函数。这种“黑盒”关系带来了三大求解障碍：

- 无解析导数（No Analytical Gradient）**：无法像高中数学那样直接对 V 求导数并令

$$\frac{d\text{MSPE}}{dV} = 0。当 \quad w_j^*(V) \text{ 碰撞到非负边界 } (w_j = 0) \text{ 时，函数会发生折面跳跃。}$$

- **非凸性 (Non-Convexity)**: 外层的 $\text{MSPE}(V)$ 曲面通常是不规则的、存在多个局部极小值 (鞍点/坑洼)。
- **计算代价高**: 外层算法每尝试一个新候选 V (比如尝试将 GDP 权重调大 0.01), 就必须重新执行一次完整的内层二次规划 (QP) 来计算新的 W^* 。

3. 外层算法的具体求解策略

为了在没有解析导数的情况下解出 V , 现代求解器通常采用以下策略:

- **有限差分数值梯度 (Finite-Difference Gradient) + L-BFGS-B**:

外层算法在当前 V 的基础上, 给第 k 个变量加上极小扰动 ϵ (如 10^{-6}), 重新调用一次内层 QP, 计算出数值上的微小变化率 $\frac{\text{MSPE}(V+\epsilon)-\text{MSPE}(V)}{\epsilon}$ 。以此近似算出梯度, 再利用 L-BFGS-B 沿陡峭方向推进。

第一步: 有限差分数值梯度 (数值试探法)

- **导数的定义**

在高中数学中, 导数定义为极限:

$$f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

当计算机无法对函数求解析导数时, 最直观的替代方案就是把 Δx 替换成一个极小的常数 ϵ (如 10^{-6}), 直接用数值计算近似代替导数。

- **多维偏导数的数值近似**

对于 K 个特征重要性变量 $V = (v_1, v_2, \dots, v_K)$, 算法需要依次探测 V 在每一个维度上的斜率 (偏导数):

- **前向差分 (Forward Difference)**:

使得第 k 个变量产生微小扰动 $v_k + \epsilon$, 其余变量不变, 记为 $V + \epsilon e_k$:

$$\frac{\partial \text{MSPE}}{\partial v_k} \approx \frac{\text{MSPE}(V + \epsilon e_k) - \text{MSPE}(V)}{\epsilon}$$

- **中心差分 (Central Difference, 更精确)**:

同时在正负两个方向扰动:

$$\frac{\partial \text{MSPE}}{\partial v_k} \approx \frac{\text{MSPE}(V + \epsilon e_k) - \text{MSPE}(V - \epsilon e_k)}{2\epsilon}$$

把这 K 个偏导数拼在一起, 就得到了外层函数的近似梯度向量 $\hat{V} \text{MSPE}(V)$ 。

代价: 计算一次中心梯度, 需要重新调用 $2K$ 次内层 QP。如果特征数 $K = 10$, 每走一步前就要先算 20 次二次规划。

第二步: L-BFGS-B 算法 (带边界的限制内存拟牛顿法)

拿到梯度 (坡度方向) 后, 算法不能像盲人下山一样只按固定步长走, 否则在平坦区域走太慢、在陡峭峡谷会来回震荡。这就需要 L-BFGS-B 算法。

- **BFGS: 用一阶导数“拼出”二阶曲率**

牛顿法需要计算海森矩阵 (二阶导数矩阵 H), 以拟合山谷的凹凸形状 (抛物线形状)。但海森矩阵计算成本太高, BFGS 算法利用一个巧妙的几何直觉:

“只要记录最近走过的几步里, 梯度的变化量 (坡度改变了多少), 就能推算出山谷的弯曲程度。”

- **L (Limited-memory): 限制内存占用**

传统的拟牛顿法需要存储整个 $K \times K$ 的曲率矩阵。L-BFGS 仅在内存中保存最近 m 步 (通常 $m = 5 \sim 10$) 的梯度向量与位置变化量。每一步需要使用二阶信息时, 通过隐式乘法 (Two-Loop Recursion) 瞬间推算出来, 内存开销降为 $O(mK)$ 。


● B (Bounds): 原生支持边界约束

由于 V 必须满足非负约束 $v_k \geq 0$ ，普通的优化算法可能会踩出边界（算出负数）。

L-BFGS-B 引入了**有效集 (Active Set) 机制**：在每一步迭代中，算法先沿着梯度方向预测，一旦发现某些变量试图穿过 0 边界，就把这些变量死死固定在 0（贴墙滑行），只在其余大于 0 的变量维度上继续寻找抛物线最低点。

C 组合运行的闭环 workflow

系统将两组算法结合，按照以下迭代循环推进：



D 工程中的隐患与应对

1. 步长 ϵ 选择的矛盾：

- ϵ 太大：无法精确近似导数，割线代替切线误差大。
- ϵ 太小（如 10^{-16} ）：超出计算机浮点数精度（舍入误差），计算出的梯度全是噪声。工程上通常设为 $\sqrt{\text{机器精度}} \approx 10^{-8}$ 或 10^{-6} 。

2. 多起点重启 (Multi-start) 应对局部最优：

由于数值梯度+L-BFGS-B 依然是局部搜索算法，当外层 $\text{MSPE}(V)$ 存在多个坑洼时，算法可能陷入离起点最近的局部极小值。工程上会随机生成几十组满足 $\sum v_k = 1$ 的初始 V_0 ，并发运行该组合算法，最后取所有结果中 MSPE 最小的那一组。

3. 时序样本分割 (Train-Validation Split) 防止过拟合：

在高级应用中，为防止 V 过度拟合干预前的所有年份，会将干预前时期拆分为训练期 (T_{train}) 和验证期 (T_{val})。内层在训练期算 W ，外层在验证期算 V 的 MSPE，以此确保选出的特征权重具有外推预测能力。

2. 线性回归权重法 (Regression-based Approach)

先使用干预前的数据，以结果变量 Y 为被解释变量、各特征 $X_1, X_2, \dots, X_K$ 为解释变量建立回归方程：

$$Y_{1t} = \beta_0 + \sum_{k=1}^K \beta_k X_{k1t} + \epsilon_t$$

根据估计出的回归系数对结果变量的解释能力（如系数绝对值 $|\hat{\beta}_k|$ 或 t 统计量）进行归一化，填入 V 的对角线：

$$v_k = \frac{|\hat{\beta}_k|}{\sum_{m=1}^K |\hat{\beta}_m|}$$

3. 等权重/单位矩阵法 (Equal Weighting / Identity Matrix)

直接设 V 为单位矩阵或等权重矩阵：

$$V = \frac{1}{K} I_K$$

这种方法假设所有预测特征同等重要。通常作为基准（Baseline）对比，或在所有输入特征都已经经过标准化（如 Z-score 归一化）且数量较少时使用。

4. 方差倒数加权法 (Inverse Variance Normalization)

按每个特征在控制池中的样本方差的倒数来设定 v_k ：

$$v_k \propto \frac{1}{\text{Var}(X_{k0})}$$

这种构造方式的主要目的是**消除量纲与数量级的影响**，防止数值范围大的变量（如 GDP 绝对值）掩盖数值范围小的变量（如失业率）。